

Licenciatura en Ingeniería en Ciencias de la Computación

Data Science

Sección: 10

Catedrático: Lynette Garcia



Proyecto #2

Javier Andres Chen – 22153
Gustavo Cruz– 22779
Mathew Cordero –22982
Pedro Pablo Guzman– 22111

11 de septiembre del 2025

1.Planteamiento inicial del problema:

Situación Problemática:

Las fracturas de las vértebras cervicales representan una de las lesiones más graves en el ámbito médico, ya que pueden derivar en discapacidad permanente o incluso la muerte si no se diagnostican y tratan a tiempo. Actualmente, los hospitales y clínicas reciben grandes cantidades de radiografías de pacientes con sospecha de trauma cervical. Sin embargo, el diagnóstico depende del criterio de radiólogos especialistas, lo cual puede generar retrasos, subjetividad y riesgo de pasar por alto fracturas sutiles.

Problema científico:

¿Es posible entrenar un modelo de visión artificial que detecte y clasifique fracturas en radiografías de las vértebras cervicales de manera confiable, contribuyendo a reducir los tiempos de diagnóstico y el margen de error humano en la interpretación médica?

Objetivos:

Objetivo general:

- Desarrollar un modelo de aprendizaje automático basado en visión por computadora que identifique fracturas en radiografías de las vértebras cervicales, con el fin de apoyar a los profesionales médicos en un diagnóstico más rápido y preciso.

Objetivos Específicos:

- Explorar y describir las características del dataset de radiografías cervicales, identificando patrones, limitaciones y posibles fuentes de sesgo en los datos.
- Aplicar estrategias de procesamiento y transformación de imágenes (reducción de ruido, estandarización de tamaños, balanceo de clases) para optimizar el desempeño del modelo.
- Comparar distintos enfoques de redes neuronales y analizar sus resultados con métricas de desempeño relevantes, seleccionando la arquitectura más prometedora para la tarea de detección.

2. Investigación Preliminar:

Descripción de la enfermedad:

Las fracturas de la columna cervical ocurren cuando una o más vértebras de la región cervical (C1–C7) sufren una ruptura parcial o total a causa de un traumatismo. Son lesiones de alta gravedad porque pueden comprometer la médula espinal y generar consecuencias neurológicas severas, como parálisis o incluso la muerte. Estas fracturas suelen estar asociadas a accidentes automovilísticos, caídas desde altura y lesiones deportivas de contacto.

Síntomas:

Los síntomas dependen de la severidad y la localización de la fractura, algunos de los más comunes son:

- Dolor intenso en el cuello y rigidez.
- Inflamación y sensibilidad localizada.
- Limitación o pérdida de movilidad en el cuello.
- Entumecimiento, hormigueo o debilidad en brazos y piernas.
- En casos graves, pérdida del control motor, dificultad respiratoria o parálisis debido a daño en la médula espinal.

Métodos de diagnóstico:

El diagnóstico clínico se basa en la combinación de exploración física, antecedentes del accidente y estudios por imágenes. Entre los principales métodos se encuentran:

- Radiografía cervical: primera herramienta diagnóstica debido a su bajo costo y disponibilidad. Permite observar alineaciones óseas, fracturas evidentes y desplazamientos vertebrales, aunque puede no detectar lesiones muy pequeñas.
- Tomografía computarizada (CT): proporciona imágenes de mayor resolución y detalle tridimensional, siendo el estándar para confirmar fracturas.
- Resonancia magnética (MRI): se utiliza principalmente para evaluar el estado de los tejidos blandos y la médula espinal, complementando la información de la radiografía o la CT.

En la práctica hospitalaria, la radiografía cervical sigue siendo fundamental como herramienta de primera línea, ya que permite descartar rápidamente fracturas evidentes y priorizar a los pacientes que requieren estudios más avanzados. Por esta razón, resulta una fuente clave de datos para entrenar modelos de visión artificial que apoyen el diagnóstico temprano y reduzcan los riesgos de error.

Resultados:

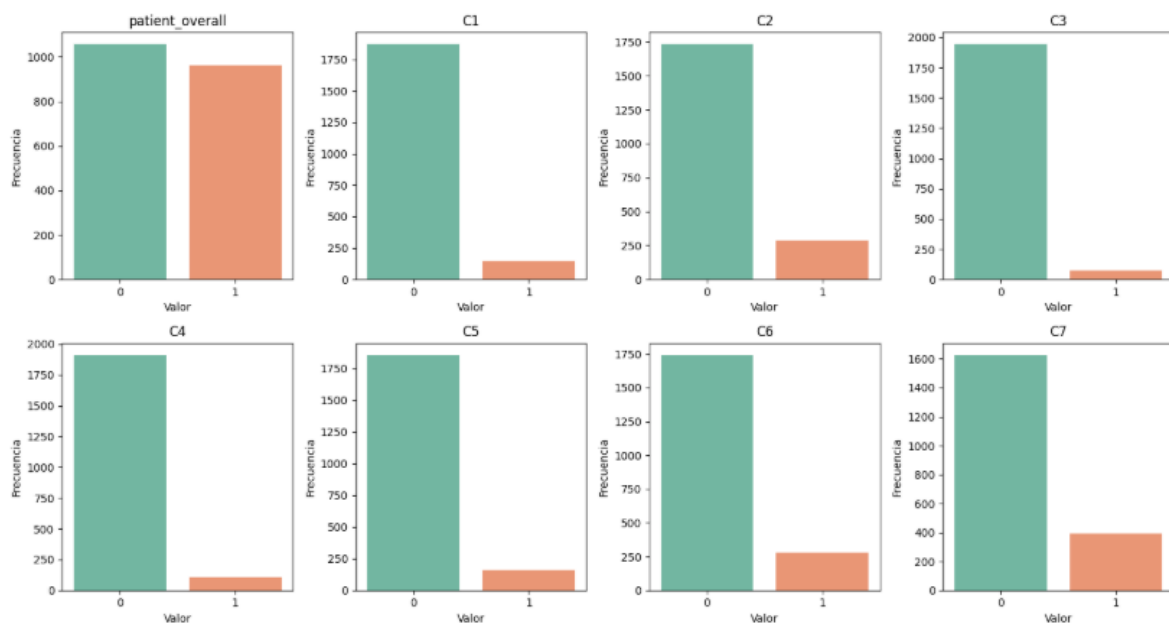


Figura 1 : Resumen variables numéricas

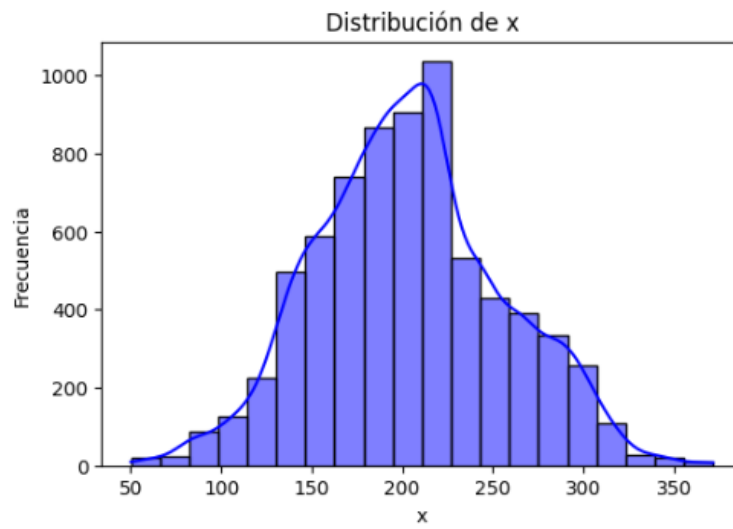


Figura 2 : Distribucion de x en el dataset `df_train_bounding_boxes`




Figura 3 : Distribucion de y en el dataset `df_train_bounding_boxes`

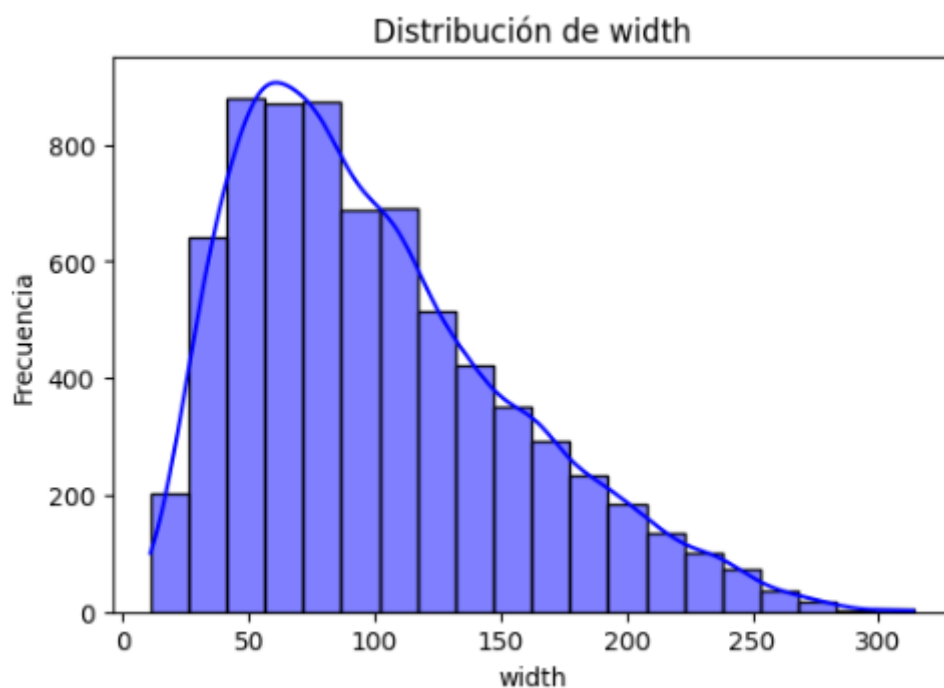


Figura 4 : Distribucion de width en el dataset `df_train_bounding_boxes`

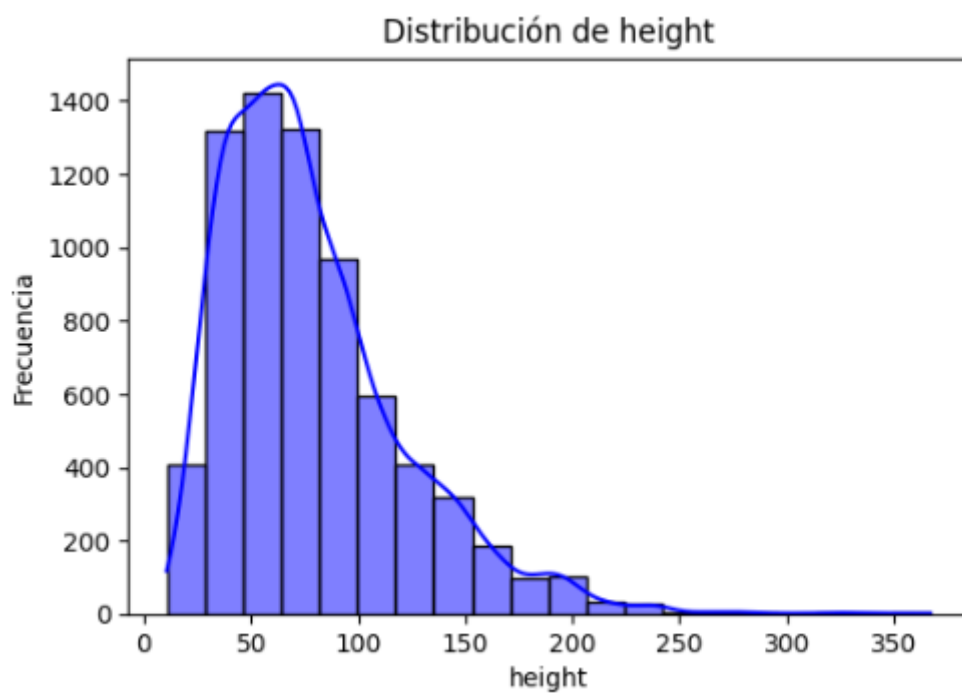


Figura 5 : Distribucion de height en el dataset `df_train_bounding_boxes`

	x	y	width	height	slice_number
count	7217.000000	7217.000000	7217.000000	7217.000000	7217.000000
mean	203.919471	181.803096	100.916069	78.787244	191.094222
std	51.855559	61.601498	54.948263	42.884778	94.565947
min	50.080550	22.062000	11.000000	10.632710	26.000000
25%	168.611300	139.000000	57.565400	47.411080	128.000000
50%	202.000000	180.000000	89.307160	70.000000	173.000000
75%	237.000000	225.000000	133.712010	99.000000	234.000000
max	371.818180	377.000000	313.657690	367.029210	483.000000

Figura 6 : Descripción del dataset df_train_bounding_boxes

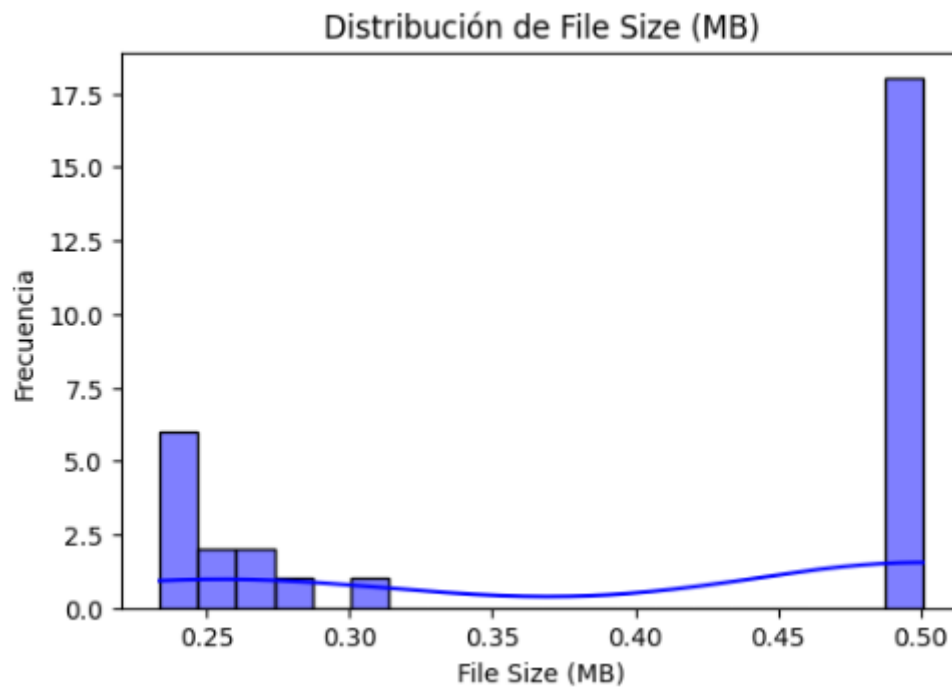


Figura 7 : Distribución de File Size

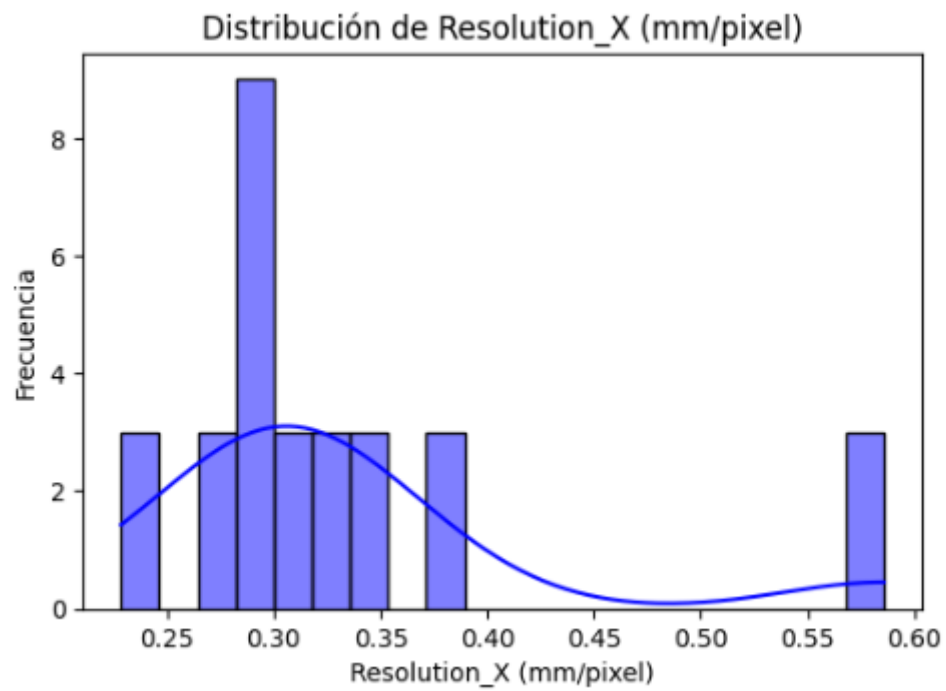


Figura 8 : Distribucion de Resolucion X mm/ pixel




Figura 9 : Distribucion de Resolucion_y

	File Size (MB)	Resolution_X (mm/pixel)	Resolution_Y (mm/pixel)
count	30.000000	30.000000	30.000000
mean	0.402913	0.333316	0.333316
std	0.122601	0.093944	0.093944
min	0.233538	0.228516	0.228516
25%	0.260263	0.285156	0.285156
50%	0.500712	0.306703	0.306703
75%	0.500734	0.341797	0.341797
max	0.500738	0.585938	0.585938

Figura 10 : Resumen del Dataset de Archivos

```
StudyInstanceUID
1.2.826.0.1.3680043.6200      1
1.2.826.0.1.3680043.29807     1
1.2.826.0.1.3680043.15845     1
1.2.826.0.1.3680043.20639     1
1.2.826.0.1.3680043.21167     1
Name: count, dtype: int64
```

Figura 11: Resumen variables categoricas




Figura 12: Fotografia de una vertebra.

```
Distribución de pacientes con fractura:  
patient_overall  
0    0.524022  
1    0.475978  
Name: proportion, dtype: float64
```

```
Frecuencia de fractura por vértebra:  
C1    0.072313  
C2    0.141159  
C3    0.036157  
C4    0.053492  
C5    0.0880238  
C6    0.137197  
C7    0.194651  
dtype: float64
```

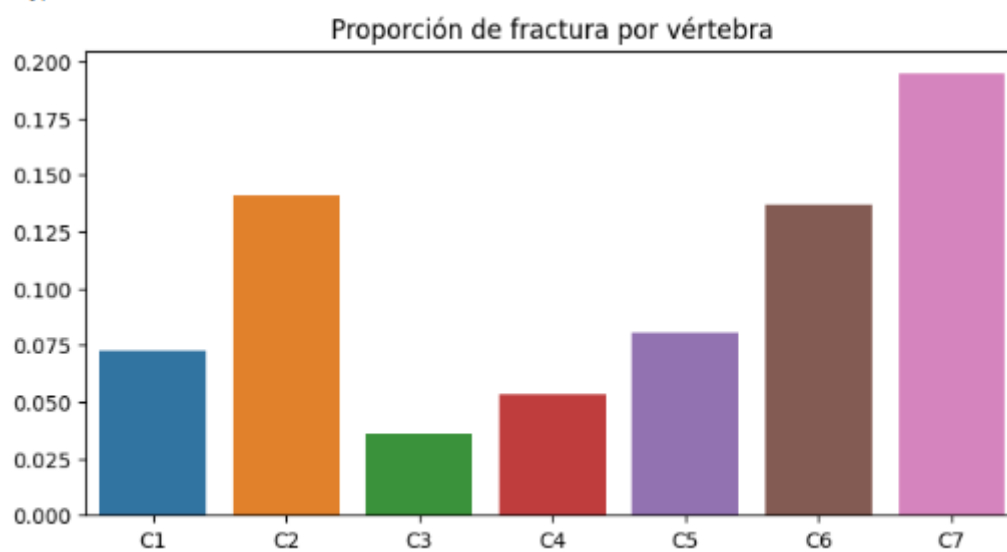


Figura 13: Proporción de fractura por vértebra.

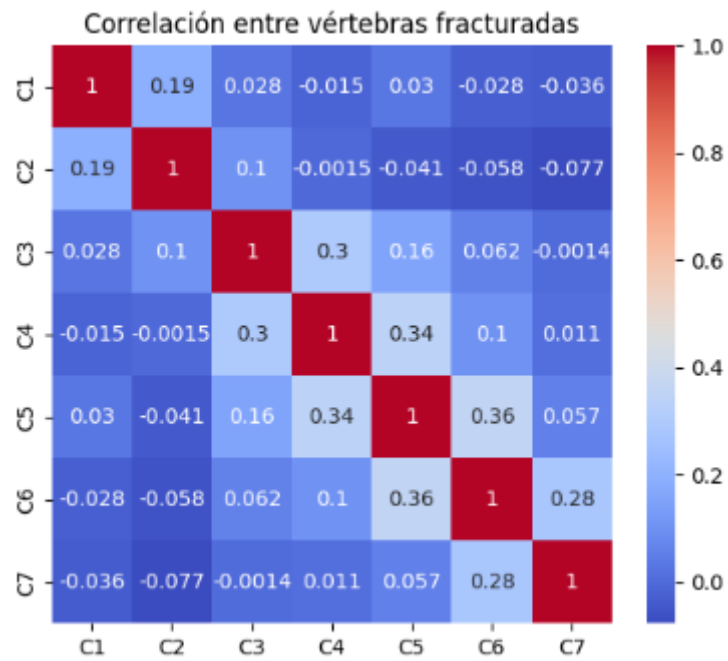


Figura 14: Correlacion entre vertebras fracturadas

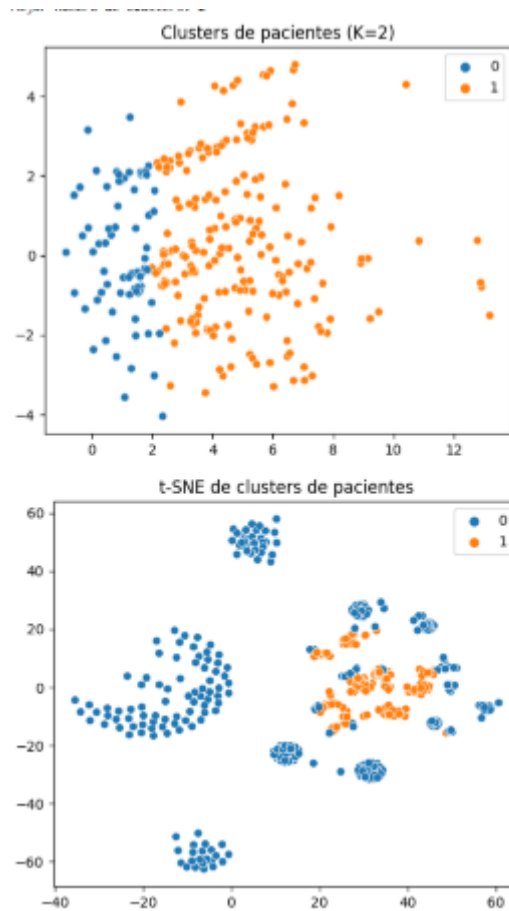


Figura 15: Clusterizacion de los datasets

```

cluster  patient_overall
0        0                0.582599
        1                0.417401
1        1                1.000000
Name: proportion, dtype: float64
      width_mean  height_mean  slice_number_count
cluster
0         50.542849    39.899831          9.628571
1        101.791158    77.409067         34.400000
      C1         C2         C3         C4         C5         C6         C7
cluster
0      0.057269  0.126101  0.012115  0.023128  0.049009  0.107379  0.177863
1      0.206897  0.275862  0.251232  0.325123  0.359606  0.403941  0.344828

```

Figura 16: Identificación de clúster

Discusión

El análisis exploratorio permitió comprender de manera más profunda las características del dataset y las posibles limitaciones para el entrenamiento de modelos de visión artificial. En primer lugar, las variaciones observadas en el tamaño de los archivos, la resolución y las dimensiones de los bounding boxes reflejan que los datos provienen de distintas fuentes y condiciones de captura. Esto puede introducir ruido en el aprendizaje automático si no se aplican técnicas de estandarización, lo cual representa un aspecto clave a considerar en la fase de preprocesamiento. Por ello se implementará una normalización en la etapa de preprocesamiento de los datos. Ello se puede ver lo que se habla en la figura 7 , 8 y 9.

En las figuras 2 y 3 se ve con el df de boxes que la mayoría de imágenes tienen el x y el y en 100, y en el caso de su width y height la tienen entre 50 y 100 como se ve en las figuras 4 y 5. Lo cual indican que en promedio si bien hay varias que varían, se tienen una gran parte centradas y en la posición que corresponde. Un ejemplo de ello son las imágenes de la figura 12

De las variables categorías se pueden ver que de todas las únicas que se tienen como categorías es el id y los Cs, de estos últimos como se ve en la figura 13 la columna C7 es la que tiene mayor cantidad de fracturas al igual que la C2 , C5 y C6.

Sabiendo esto se hizo un análisis de correlación de vertebras y se encontró que las que estaban más correlacionadas son las que físicamente están como vecinas en el cuerpo humano. Como se ve en la figura 14, pero ojo estas correlaciones no son positivas son negativas, lo cual puede indicar que la presencia de una fractura en cierta vértebra reduce la probabilidad de que se manifieste en la adyacente.

Esto sugiere que, aunque existe una relación entre la proximidad anatómica y la ocurrencia de fracturas, estas no necesariamente se presentan de forma simultánea en vértebras contiguas.

Después se hizo una clusterización y se crearon 2 clusters evidentes en la figura 15, pero para realizar un análisis más profundo de cada cluster se obtuvo la tabla de la figura 16. Esta indica que :

- Cluster 0

58% no fracturados / 42% fracturados → es un grupo mixto, pero con mayoría sin fractura.

Bounding boxes pequeños → ancho ≈ 50 , alto ≈ 40 , slices ≈ 10 .

Baja frecuencia de fractura en vértebras (todas $< 20\%$).

Este grupo representa a los pacientes sin fracturas o con fracturas leves y localizadas.

- Cluster 1

100% fracturados → es un grupo exclusivo de pacientes fracturados.

Bounding boxes grandes → ancho ≈ 100 , alto ≈ 77 , slices ≈ 34 (mucho mayor extensión en las imágenes).

Alta frecuencia de fractura en todas las vértebras → especialmente C5 (36%), C6 (40%), y C7 (34%).

Este grupo representa a los pacientes con fracturas severas y múltiples vértebras afectadas, con cambios estructurales que hacen que las cajas sean mucho más grandes

Por lo tanto tenemos a que los pacientes que tienen fracturas llegan a ocupar más píxeles de la imagen y a estar más amplia la misma. En cambio aquellos que no la imagen suele ser más angosta.

Conclusiones

El análisis exploratorio permitió identificar que el dataset presenta una adecuada cantidad de imágenes con información detallada sobre las vértebras cervicales, aunque con variaciones importantes en tamaño de archivo, resolución y dimensiones de los bounding boxes. Estas diferencias sugieren la necesidad de normalizar y estandarizar

las imágenes antes de entrenar cualquier modelo de visión artificial, con el fin de reducir sesgos y mejorar la consistencia en el aprendizaje.

En cuanto a la distribución de las fracturas, se observa un desbalance entre vértebras: algunas presentan una mayor proporción de lesiones mientras que otras son poco frecuentes. Este desbalance es un reto importante, ya que puede sesgar el modelo hacia las clases más representadas, lo cual hace necesario aplicar técnicas de balanceo o ponderación durante el entrenamiento. Asimismo, las correlaciones detectadas entre fracturas de vértebras sugieren que las lesiones no siempre ocurren de forma aislada, lo que podría aprovecharse como una señal adicional para el modelo.

Finalmente, el análisis de los clusters evidenció la existencia de grupos diferenciados dentro del dataset, lo que indica que no todas las imágenes presentan las mismas características. Este hallazgo refuerza la importancia de un preprocesamiento cuidadoso para mejorar la generalización del modelo.

Repositorio

https://github.com/G2309/DS_Project2.git

Bibliografía

Graber, M. A., & Kathol, M. (1999, 15 enero). *Cervical Spine Radiographs in the Trauma Patient*. AAFP. https://www.aafp.org/pubs/afp/issues/1999/0115/p331.html?utm_source

Radiografía de la columna vertebral | Cigna. (s. f.). <https://www.cigna.com/es-us/knowledge-center/hw/pruebas-mdicas/radiografa-de-la-columna-vertebral-hw214403>